SwinTransformerV2 模型自验报告

邢朝龙 kaierlong@126.com

1. 模型简介

1.1 网络模型结构简介

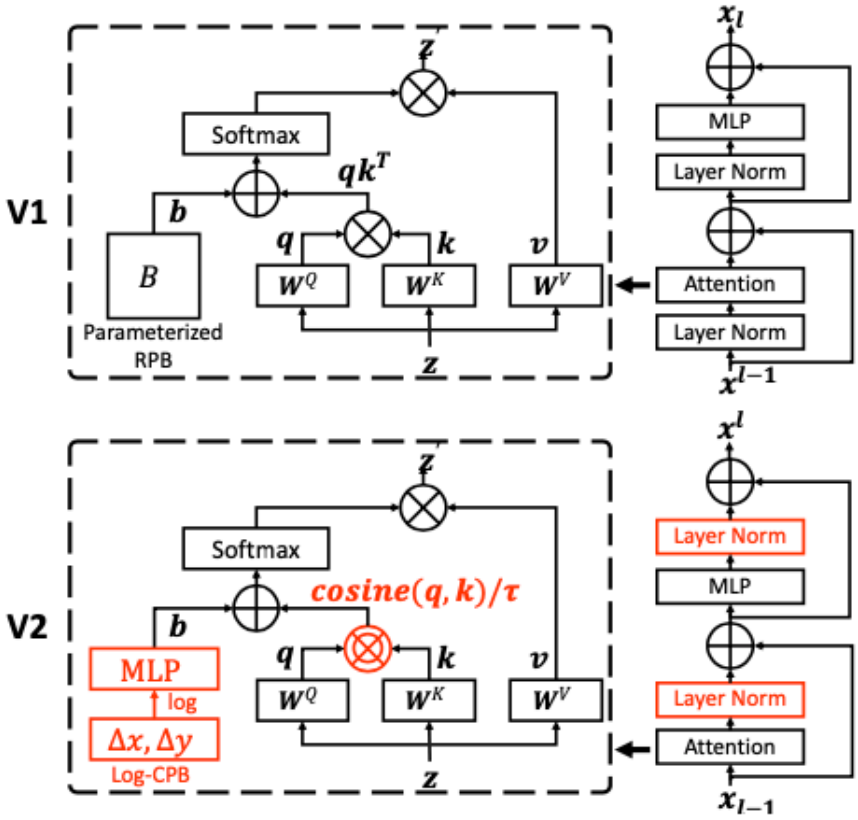

Figure 1. To better scale up model capacity and window resolution, several adaptions are made on the original Swin Transformer architecture (V1): 1) A *res-post-norm* to replace the previous *pre-norm* configuration; 2) A *scaled cosine attention* to replace the original *dot product attention*; 3) A *log-spaced continuous* relative position bias approach to replace the previous *parameterized* approach. Adaptions 1) and 2) make it easier for the model to scale up capacity. Adaption 3) makes the model to be transferred more effectively across window resolutions. The adapted architecture is named Swin Transformer V2.

`Swin Transformer V2`是微软团队在`Swin Transformer（V1）`基础上提出的升级版网络结构。

在现有的视觉大模型中，主要存在几方面问题：

1. 增大视觉模型时可能带来很大的训练不稳定性
2. 对于需要高分辨率的下游任务，并没有很好的探索出对低分辨率下训练好的模型迁移到更大scale模型上的方法
3. GPU内存占用太大

针对以上问题，`Swin Transformer V2`主要提出三个改进点：

1. post normalization：在self-attention layer和MLP block后进行layer normalization
2. scaled cosine attention approach：使用cosine相似度来计算token pair之间的关系
3. log-spaced continuous position bias：重新定义相对位置编码

1.2 数据集

> 所用数据集地址：https://git.openi.org.cn/kaierlong/imagenet2012_whole/datasets

使用训练及测试数据集如下：

```
使用的数据集：ImageNet2012

数据集大小：共1000个类、224*224彩色图像
训练集：共1,281,167张图像
测试集：共50,000张图像
数据格式：JPEG
注：数据在dataset.py中处理。
下载数据集，目录结构如下：
└─dataset
    ├─train                 # 训练数据集
    └─val                   # 评估数据集
```

1.3 代码提交地址

暂时提交在启智中，私有未开源。

仓库地址如下：https://git.openi.org.cn/OpenZAI_ZERO/Swin-Transformer-V2

2. 代码目录结构说明

代码目录结构及说明如下：

```
.
├── README.md                   // 说明文档
├── README_CN.md                // 中文说明文档
```

```
├── conv_pth2ckpt.py            // 预训练权重转换
├── eval.py                     // 评估文件
├── image                       // 文档图片目录
├── src
│   ├── args.py
│   ├── configs                 // 模型参数配置目录
│   │   ├── parser.py
│   │   ├── swin_tiny_patch4_window7_224.yaml
│   │   ├── swinv2_base_patch4_window12to16_192to256_22kto1k_ft.ckpt  // 预训练权重文件
│   │   ├── swinv2_base_patch4_window12to16_192to256_22kto1k_ft.yaml
│   │   ├── swinv2_base_patch4_window8_256.yaml
│   │   ├── swinv2_large_patch4_window16_256.yaml
│   │   ├── swinv2_small_patch4_window8_256.yaml
│   │   └── swinv2_tiny_patch4_window8_256.yaml
│   ├── data                    // 数据加载及处理目录
│   │   ├── __init__.py
│   │   ├── augment
│   │   │   ├── __init__.py
│   │   │   ├── auto_augment.py
│   │   │   ├── custom_transforms.py
│   │   │   ├── mixup.py
│   │   │   └── random_erasing.py
│   │   ├── data_utils
│   │   │   ├── __init__.py
│   │   │   └── moxing_adapter.py
│   │   └── imagenet.py
│   ├── image22kto1k.txt        // 22K转1K数据集ID映射表
│   ├── models                  // 模型定义目录
│   │   ├── __init__.py
│   │   └── swintransformer
│   │       ├── __init__.py
│   │       ├── clip_ops.py
│   │       ├── get_swin.py
│   │       ├── get_swin_v2.py
│   │       ├── misc.py
│   │       ├── swin_transformer.py
│   │       └── swin_transformer_v2.py    // swin transformer v2定义文件
│   ├── tools                   // 相关工具目录
│   │   ├── __init__.py
│   │   ├── callback.py
│   │   ├── cell.py
│   │   ├── criterion.py
│   │   ├── get_misc.py
│   │   ├── optimizer.py
│   │   └── schedulers.py
│   └── trainers              // 训练目录
│       ├── __init__.py
│       ├── model_ema.py
│       ├── train_one_step_with_ema.py
```

```
│       └── train_one_step_with_scale_and_clip_global_norm.py
└── train.py             // 训练文件
```

3. 自验结果（交付精度规格时需要补齐）

3.1 自验环境

软硬件环境如下：

- 启智AI引擎：MindSpore-1.5.1-c79-python3.7-euleros2.8-aarch64
- Ascend: 8 * Ascend-910(32GB) | ARM: 192 核 2048GB

详细环境配置参见下图：

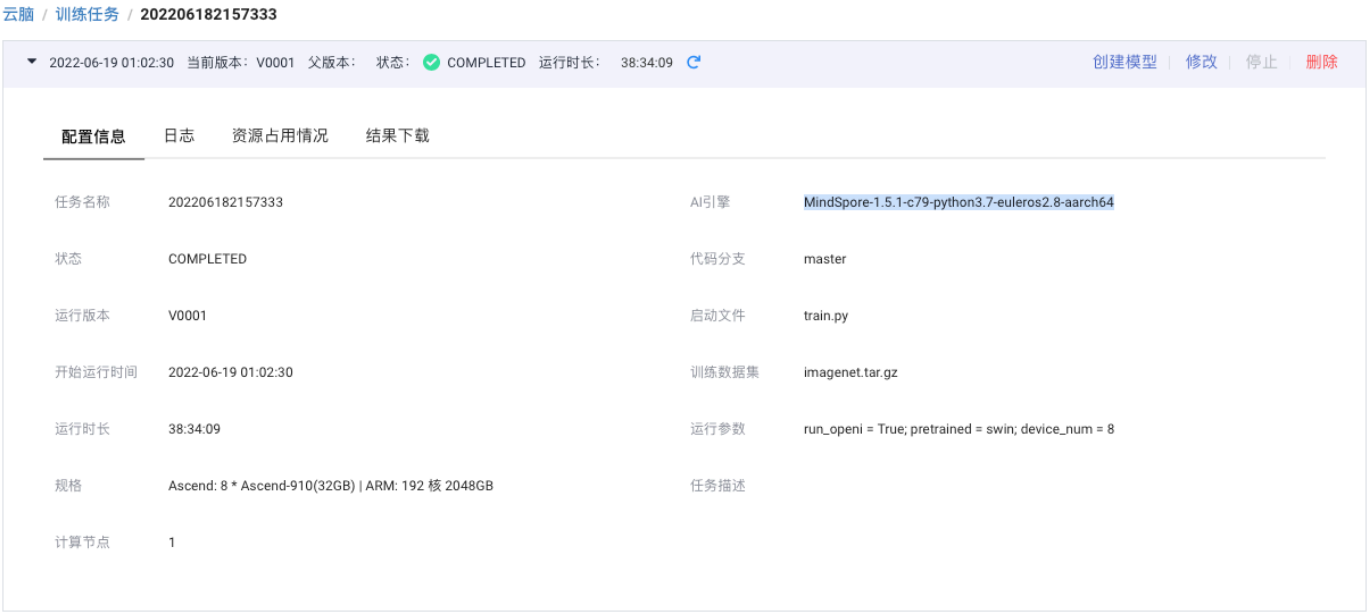

3.2 训练超参数

超参数配置如下：

> 其中data_url由启智平台实际数据地址替换，训练时替换。

```yaml
# Architecture
arch: swinv2_base_patch4_window12to16_192to256_22kto1k_ft

# ===== Dataset ===== #
data_url: ./data/imagenet
set: ImageNet
num_classes: 1000
mix_up: 0.8
cutmix: 1.0
```

```yaml
auto_augment: rand-m9-mstd0.5-inc1
interpolation: bicubic
re_prob: 0.25
re_mode: pixel
re_count: 1
mixup_prob: 1.
switch_prob: 0.5
mixup_mode: batch
crop_ratio: 0.875


# ===== Learning Rate Policy ======== #
optimizer: adamw
lr_scheduler: cosine_lr
base_lr: 0.00005
min_lr: 0.0000002
warmup_length: 5
warmup_lr: 0.00000002
cool_length: 10
cool_lr: 0.0000002
nonlinearity: GELU


# ===== Network training config ===== #
amp_level: O1
keep_bn_fp32: True
beta: [ 0.9, 0.999 ]
is_dynamic_loss_scale: True
use_global_norm: True
clip_global_norm_value: 5.
enable_ema: False
ema_decay: 0.9999
loss_scale: 1024
weight_decay: 0.00000001
momentum: 0.9
label_smoothing: 0.1
epochs: 40
batch_size: 32


# ===== Hardware setup ===== #
num_parallel_workers: 32
device_target: Ascend

# ===== Model config ===== #
drop_path_rate: 0.2
embed_dim: 128
depths: [ 2, 2, 18, 2 ]
num_heads: [ 4, 8, 16, 32 ]
```

```
window_size: 16
image_size: 256
pretrained_window_sizes: [ 12, 12, 12, 6 ]
```

3.3 训练

> 说明：
>
> 因为需要用到预训练模型，需要将pytorch模型进行转换，转换命令如下：
>
> 提前下载pytorch模型：
>
> - github地址：https://github.com/SwinTransformer/storage/releases/download/v2.0.0/swinv2_base_patch4_window12_192_22k.pth
> - 百度网盘：https://pan.baidu.com/s/1Xc2rsSsRQz_sy5mjgfxrMQ?pwd=swin
>
> ```
> # 友情提示需要用到pytorch环境
> python3 conv_pth2ckpt.py --pth_file=swinv2_base_patch4_window12_192_22k.pth --ckpt_file=src/configs/swinv2_base_patch4_window12to16_192to256_22kto1k_ft.ckpt src/configs/swinv2_base_patch4_window12to16_192to256_22kto1k_ft.ckpt --cls_map_file=src/image22kto1k.txt
> ```

3.3.1 如何启动训练脚本

训练如何启动：

- 启智平台

模型训练在启智平台完成，完整训练配置如下图所示：

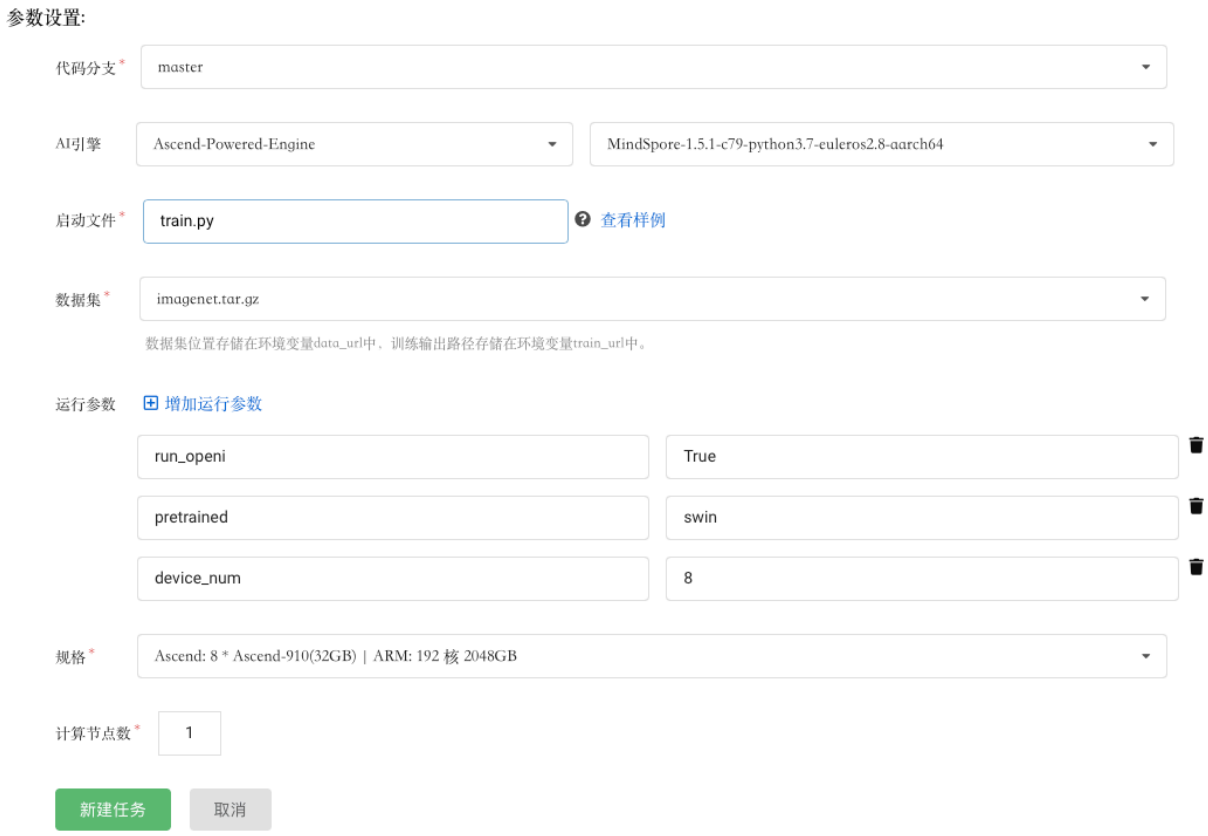

- 本地命令

如果需要本地训练，可以使用如下命令：

```
python3 train.py --run_openi=True --
arch=swinv2_base_patch4_window12to16_192to256_22kto1k_ft --pretrained=swin --
device_num=8
```

3.3.2 训练精度结果

- 论文精度如下:

ImageNet-1K and ImageNet-22K Pretrained Swin-V2 Models

name	pretrain	resolution	window	acc@1	acc@5	#params	FLOPs	FPS	
SwinV2-T	ImageNet-1K	256x256	8x8	81.8	95.9	28M	5.9G	572	
SwinV2-S	ImageNet-1K	256x256	8x8	83.7	96.6	50M	11.5G	327	
SwinV2-B	ImageNet-1K	256x256	8x8	84.2	96.9	88M	20.3G	217	
SwinV2-T	ImageNet-1K	256x256	16x16	82.8	96.2	28M	6.6G	437	
SwinV2-S	ImageNet-1K	256x256	16x16	84.1	96.8	50M	12.6G	257	
SwinV2-B	ImageNet-1K	256x256	16x16	84.6	97.0	88M	21.8G	174	
SwinV2-B*	ImageNet-22K	256x256	16x16	86.2	97.9	88M	21.8G	174	g
SwinV2-B*	ImageNet-22K	384x384	24x24	87.1	98.2	88M	54.7G	57	g
SwinV2-L*	ImageNet-22K	256x256	16x16	86.9	98.0	197M	47.5G	95	g
SwinV2-L*	ImageNet-22K	384x384	24x24	87.6	98.3	197M	115.4G	33	g

- 复现精度如下：
  - 30 epochs

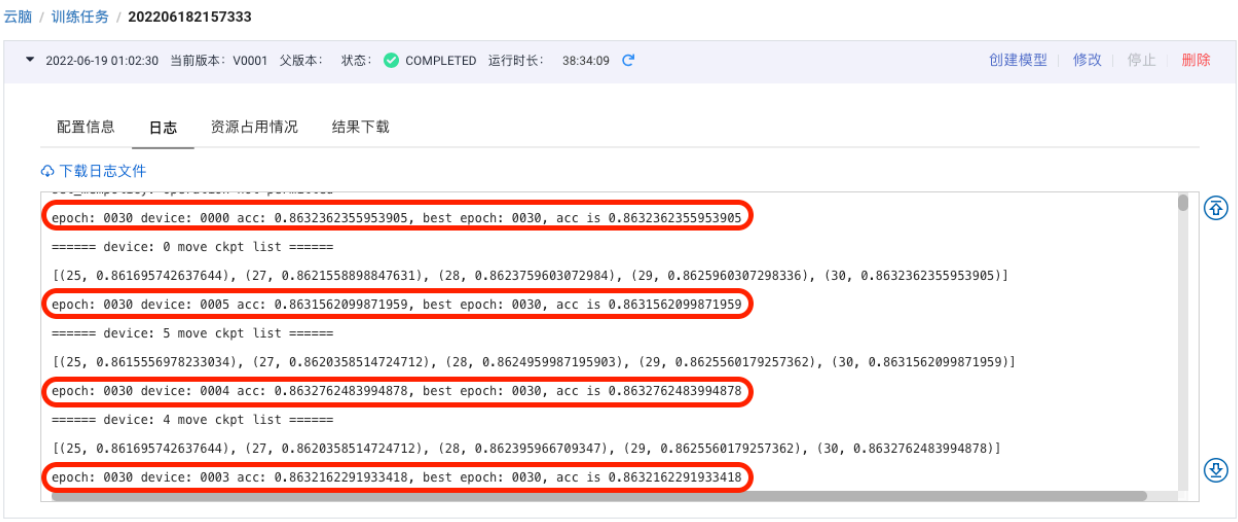

  - 40 epochs

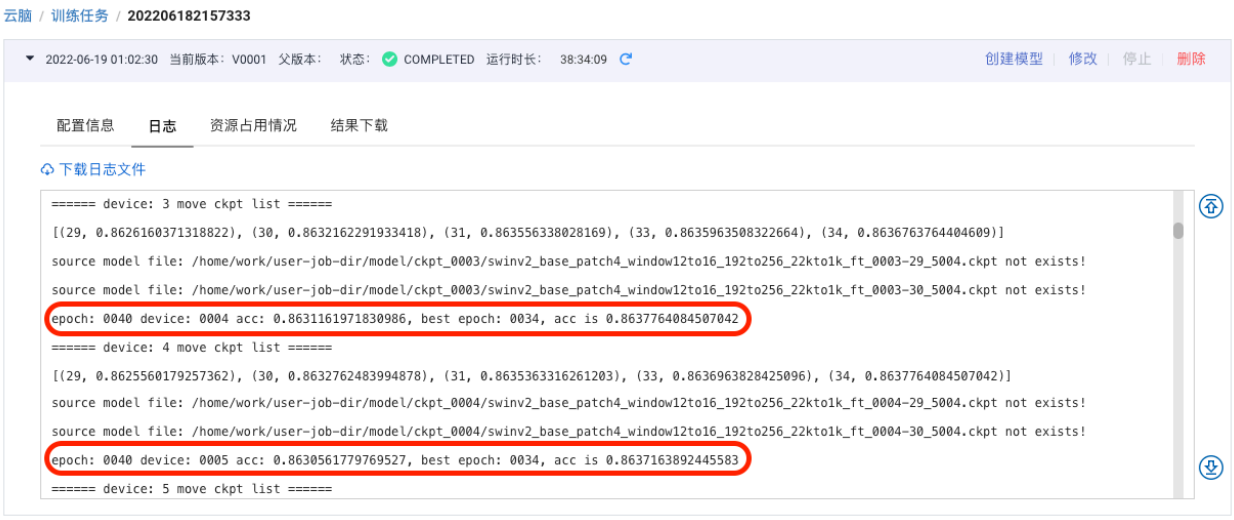

- 精度结果对比
  - 论文精度为：86.2
- 复现精度为：
  - 86.32 （30 epochs，同论文一致）
  - 86.37 （40 epochs，自己增加了10个cooldown epochs）
- 结论：可以看出即便跟论文一致时，依然已经超过了论文中`86.2`的精度。

3.4 模型推理

推理命令如下：

```
python3 eval.py --
config=src/configs/swinv2_base_patch4_window12to16_192to256_22kto1k_ft.yaml --
pretrained={ckpt_path} --device_id={device_id} --device_target={device_target} --
data_url={data_url}
```

4. 参考资料

4.1 参考论文

- [2111.09883] Swin Transformer V2: Scaling Up Capacity and Resolution (arxiv.org)

4.2 参考git项目

- microsoft/Swin-Transformer: This is an official implementation for "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows". (github.com)

4.3 参考文献

- 【简读】Swin Transformer V2: Scaling Up Capacity and Resolution - 知乎 (zhihu.com)